

TRƯỜNG ĐẠI HỌC KỸ THUẬT CÔNG NGHIỆP

KHOA ĐIỆN TỬ

Bộ môn: Công nghệ Thông tin

BÀI TIỂU LUẬN

MÔN HỌC

KHOA HỌC DỮ LIỆU

Sinh viên: PHẠM MẠNH QUỲNH

Lớp: K58KTP.K01

Giáo viên hướng dẫn: TS. Nguyễn Văn Huy

Thái Nguyên – 2026

BÀI TIỂU LUẬN

MÔN HỌC: KHOA HỌC DỮ LIỆU

BỘ MÔN : CÔNG NGHỆ THÔNG TIN

Sinh viên: *Phạm Mạnh Quỳnh*

Lớp: *K58KTP.K01*

Ngành: *Kỹ Thuật Máy Tính*

Giáo viên hướng dẫn: *TS. Nguyễn Văn Huy*

Ngày giao đề : *07/06/2026* Ngày hoàn thành : *21/06/2026*

Tên đề tài : *PHÂN TÍCH VÀ KHÁM PHÁ CÁC NHÓM KHÁCH HÀNG DỰA TRÊN DỮ LIỆU ĐẶT PHÒNG KHÁCH SẠN BẰNG KỸ THUẬT PHÂN CỤM K-MEANS*

Yêu cầu :

Xây dựng chương trình phân tích dữ liệu đặt phòng khách sạn bằng Python, thực hiện tiền xử lý dữ liệu, áp dụng thuật toán phân cụm K-Means để khám phá các nhóm khách hàng có đặc điểm tương đồng, đồng thời đánh giá và trực quan hóa kết quả phân cụm.

GIÁO VIÊN HƯỚNG DẪN

(Ký và ghi rõ họ tên)

NHẬN XÉT CỦA GIÁO VIÊN CHẤM

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

GIÁO VIÊN HƯỚNG DẪN

(Ký ghi rõ họ tên)

MỤC MỤC

LỜI NÓI ĐẦU	6
CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI.....	7
1.1. Ý nghĩa đề tài.....	7
1.2. Phạm vi đề tài	9
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT	12
2.1. Tổng quan về khoa học dữ liệu	12
2.2. Khai phá dữ liệu và phân tích dữ liệu.....	12
2.3. Thuật toán phân cụm K-Means	13
2.4. Chuẩn hóa dữ liệu bằng StandardScaler.....	14
2.5. Đánh giá mô hình bằng Silhouette Score	15
2.6. Trực quan hóa dữ liệu bằng PCA	15
CHƯƠNG 3. THIẾT KẾ VÀ XÂY DỰNG HỆ THỐNG.....	16
3.1. Thiết kế hệ thống	16
3.2. Thuật toán và quy trình xử lý dữ liệu	17
3.4. Xây dựng chương trình.....	20
CHƯƠNG 4. THỰC NGHIỆM VÀ KẾT LUẬN.....	21
4.1. Thực nghiệm.....	21
4.1.1. Môi trường thực nghiệm.....	21
4.1.2. Quy trình thực nghiệm.....	22
4.1.3. Kết quả phân tích dữ liệu.....	22
4.1.4. Kết quả phân cụm K-Means	26
4.1.5. Định hướng mở rộng	29
4.2. Kết luận.....	29

KẾT LUẬN.....	31
TÀI LIỆU THAM KHẢO.....	32

LỜI NÓI ĐẦU

Trong thời đại công nghệ số hiện nay, dữ liệu ngày càng đóng vai trò quan trọng trong nhiều lĩnh vực của đời sống và sản xuất. Việc khai thác và phân tích dữ liệu không chỉ giúp lưu trữ thông tin mà còn hỗ trợ phát hiện các xu hướng, đặc điểm và đưa ra quyết định hiệu quả hơn. Khoa học dữ liệu vì vậy đã trở thành một lĩnh vực có tính ứng dụng cao và được sử dụng rộng rãi trong thực tế.

Xuất phát từ mục tiêu vận dụng các kiến thức đã học vào giải quyết một bài toán thực tế, em thực hiện đề tài: **“Phân tích và khám phá các nhóm khách hàng dựa trên dữ liệu đặt phòng khách sạn bằng kỹ thuật phân cụm K-Means”**.

Đề tài tập trung nghiên cứu quy trình xử lý dữ liệu, lựa chọn thuộc tính phù hợp, áp dụng thuật toán K-Means để phân cụm và phân tích đặc điểm của các nhóm khách hàng dựa trên dữ liệu đặt phòng khách sạn. Thông qua quá trình thực hiện, đề tài góp phần củng cố kiến thức về khoa học dữ liệu, đồng thời giúp hiểu rõ hơn cách ứng dụng dữ liệu trong việc hỗ trợ phân tích và ra quyết định.

Do thời gian thực hiện và kiến thức còn hạn chế nên báo cáo khó tránh khỏi những thiếu sót. Em mong nhận được những góp ý từ giảng viên để tiếp tục hoàn thiện đề tài trong thời gian tới.

Em xin chân thành cảm ơn.

CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI

1.1. Ý nghĩa đề tài

Trong những năm gần đây, sự phát triển mạnh mẽ của công nghệ thông tin cùng với quá trình chuyển đổi số đã làm cho dữ liệu trở thành một nguồn tài nguyên có giá trị trong hầu hết các lĩnh vực của đời sống và sản xuất. Các tổ chức và doanh nghiệp hiện nay không chỉ tập trung vào việc thu thập dữ liệu mà còn chú trọng đến việc khai thác dữ liệu nhằm tạo ra thông tin hữu ích phục vụ quá trình ra quyết định.

Trong lĩnh vực dịch vụ lưu trú và khách sạn, dữ liệu được tạo ra liên tục từ các hoạt động đặt phòng, quản lý khách hàng và vận hành hệ thống. Mỗi giao dịch đặt phòng đều chứa nhiều thông tin như thời gian đặt trước, thời gian lưu trú, giá phòng, yêu cầu đặc biệt của khách hàng hoặc lịch sử sử dụng dịch vụ. Những dữ liệu này phản ánh đặc điểm và hành vi của khách hàng trong quá trình sử dụng dịch vụ.

Tuy nhiên, việc lưu trữ dữ liệu đơn thuần không mang lại nhiều giá trị nếu dữ liệu không được phân tích và xử lý hiệu quả. Khi số lượng bản ghi tăng lên, việc sử dụng các phương pháp thống kê truyền thống hoặc phân tích thủ công sẽ gặp nhiều khó khăn, đặc biệt trong việc phát hiện các đặc điểm ẩn hoặc xu hướng bên trong tập dữ liệu.

Khoa học dữ liệu (Data Science) là lĩnh vực kết hợp giữa thống kê, lập trình và khai phá dữ liệu nhằm khai thác tri thức từ dữ liệu. Trong đó, phân cụm dữ liệu (Clustering) là một kỹ thuật quan trọng giúp nhóm các đối tượng có đặc điểm tương đồng mà không cần xác định trước nhãn dữ liệu.

Một trong những thuật toán phân cụm phổ biến hiện nay là K-Means. Thuật toán này hoạt động bằng cách chia tập dữ liệu thành K nhóm dựa trên khoảng cách giữa các đối tượng dữ liệu và tâm cụm. Với ưu điểm đơn giản, dễ triển khai và tốc độ xử lý nhanh, K-Means được sử dụng rộng rãi trong nhiều bài toán thực tế như phân tích khách hàng, đề xuất sản phẩm và khai phá dữ liệu.

Xuất phát từ những lý do trên, đề tài **“Phân tích và khám phá các nhóm khách hàng dựa trên dữ liệu đặt phòng khách sạn bằng kỹ thuật phân cụm K-Means”**

được lựa chọn nhằm nghiên cứu khả năng ứng dụng các kỹ thuật khoa học dữ liệu vào phân tích dữ liệu thực tế.

Thông qua đề tài, sinh viên có cơ hội tiếp cận quy trình làm việc của một bài toán khoa học dữ liệu từ khâu xử lý dữ liệu đến xây dựng mô hình và đánh giá kết quả.

Đề tài mang lại các ý nghĩa sau:

Ý nghĩa về mặt học thuật

- Giúp vận dụng kiến thức về khoa học dữ liệu vào bài toán thực tế.
- Hiểu rõ quy trình phân tích và xử lý dữ liệu.
- Làm quen với các thư viện xử lý dữ liệu bằng Python.
- Nâng cao khả năng trực quan hóa và đánh giá dữ liệu.

Ý nghĩa về mặt thực tiễn

- Hỗ trợ xác định các nhóm khách hàng có hành vi tương đồng.
- Góp phần nâng cao hiệu quả quản lý dữ liệu.
- Hỗ trợ doanh nghiệp hiểu rõ hơn về nhu cầu khách hàng.
- Làm cơ sở cho các nghiên cứu dự đoán hoặc đề xuất dịch vụ trong tương lai.

Khảo sát các hệ thống tương tự

Hiện nay nhiều nền tảng đặt phòng khách sạn đã ứng dụng phân tích dữ liệu và trí tuệ nhân tạo để hỗ trợ hoạt động kinh doanh.

Ví dụ như hệ thống Booking và Agoda sử dụng dữ liệu người dùng để:

- Đề xuất khách sạn phù hợp.
- Gợi ý giá và ưu đãi.
- Phân tích xu hướng sử dụng dịch vụ.
- Cá nhân hóa trải nghiệm người dùng.

Ưu điểm:

- Xử lý lượng dữ liệu lớn.
- Tăng hiệu quả vận hành.
- Hỗ trợ ra quyết định nhanh.

Nhược điểm:

- Chi phí triển khai cao.

- Phụ thuộc vào chất lượng dữ liệu.
- Khó giải thích kết quả trong một số trường hợp.

Khác với các hệ thống thương mại, đề tài này tập trung xây dựng mô hình nghiên cứu ở quy mô nhỏ nhằm minh họa quy trình phân tích dữ liệu bằng các công cụ mã nguồn mở.

1.2. Phạm vi đề tài

Đề tài tập trung xây dựng một quy trình phân tích dữ liệu đặt phòng khách sạn bằng Python nhằm thực hiện phân cụm khách hàng dựa trên hành vi đặt phòng.

Mục tiêu chính của hệ thống là khám phá các nhóm khách hàng có đặc điểm tương đồng thông qua dữ liệu lịch sử.

Chức năng của hệ thống

Hệ thống được xây dựng với các chức năng chính như sau:

Thu thập và đọc dữ liệu

Dữ liệu được sử dụng trong đề tài là tập dữ liệu đặt phòng khách sạn ở định dạng CSV. Chương trình có nhiệm vụ đọc và chuyển đổi dữ liệu thành cấu trúc phù hợp để xử lý.

Tiền xử lý dữ liệu

Dữ liệu sau khi đọc sẽ được thực hiện các bước:

- Kiểm tra dữ liệu thiếu.
- Loại bỏ dữ liệu trùng lặp.
- Loại bỏ thuộc tính không cần thiết.
- Chuẩn hóa dữ liệu.

Phân tích dữ liệu

Thực hiện thống kê mô tả và khảo sát đặc điểm của dữ liệu nhằm lựa chọn các thuộc tính phù hợp cho bài toán phân cụm.

Phân cụm dữ liệu

Áp dụng thuật toán K-Means để chia tập dữ liệu thành các nhóm khách hàng khác nhau dựa trên mức độ tương đồng.

Đánh giá kết quả

Sử dụng chỉ số Silhouette Score để đánh giá chất lượng phân cụm và sử dụng PCA để trực quan hóa dữ liệu.

Đầu vào và đầu ra

Đầu vào

- Dữ liệu đặt phòng khách sạn.

Đầu ra

- Danh sách các cụm khách hàng.
- Đặc điểm trung bình của từng cụm.
- Biểu đồ trực quan hóa.

Công nghệ sử dụng

Ngôn ngữ:

- Python

Thư viện:

- Pandas
- Matplotlib
- Seaborn
- Scikit-learn

Công cụ:

- Visual Studio Code
- Jupyter Notebook

Giới hạn đề tài

Đề tài chỉ tập trung vào bài toán phân cụm và phân tích dữ liệu.

Một số giới hạn gồm:

- Không thực hiện dự đoán dữ liệu tương lai.
- Không sử dụng dữ liệu thời gian thực.
- Không triển khai hệ thống trực tuyến.
- Không so sánh nhiều thuật toán phân cụm khác nhau.

Mặc dù còn giới hạn về phạm vi, đề tài vẫn đảm bảo thực hiện đầy đủ quy trình xử lý và phân tích dữ liệu, đồng thời đáp ứng mục tiêu nghiên cứu và yêu cầu của môn học.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT

2.1. Tổng quan về khoa học dữ liệu

Khoa học dữ liệu (Data Science) là lĩnh vực kết hợp giữa thống kê, lập trình và khai phá dữ liệu nhằm trích xuất thông tin có giá trị từ dữ liệu. Mục tiêu của khoa học dữ liệu là biến dữ liệu thô thành tri thức hỗ trợ quá trình phân tích và ra quyết định.

Trong thực tế, khoa học dữ liệu được ứng dụng rộng rãi trong nhiều lĩnh vực như thương mại điện tử, tài chính, y tế, giáo dục và du lịch. Đối với ngành khách sạn, khoa học dữ liệu hỗ trợ phân tích hành vi khách hàng, tối ưu dịch vụ và nâng cao hiệu quả quản lý.

Một quy trình khoa học dữ liệu cơ bản thường gồm các bước:

- Thu thập dữ liệu.
- Làm sạch dữ liệu.
- Khám phá và phân tích dữ liệu.
- Xây dựng mô hình.
- Đánh giá kết quả.
- Trực quan hóa và đưa ra kết luận.

Trong đề tài này, quy trình trên được áp dụng để xử lý dữ liệu đặt phòng khách sạn và thực hiện phân cụm khách hàng.

2.2. Khai phá dữ liệu và phân tích dữ liệu

Khai phá dữ liệu (Data Mining) là quá trình tìm kiếm các mẫu, mối quan hệ và tri thức tiềm ẩn bên trong tập dữ liệu lớn.

Mục tiêu của khai phá dữ liệu không chỉ dừng ở việc mô tả dữ liệu mà còn hỗ trợ đưa ra dự đoán hoặc phát hiện các nhóm dữ liệu có đặc điểm giống nhau.

Một số hướng tiếp cận phổ biến gồm:

Phân tích mô tả (Descriptive Analysis)

Được sử dụng để trả lời câu hỏi:

- Điều gì đã xảy ra?

- Dữ liệu hiện tại đang thể hiện điều gì?

Ví dụ:

- Tỷ lệ khách hàng hủy đặt phòng.
- Giá phòng trung bình.
- Phân bố số lượng yêu cầu đặc biệt.

Phân tích dự đoán (Predictive Analysis)

Được sử dụng để dự đoán kết quả dựa trên dữ liệu lịch sử.

Ví dụ:

- Dự đoán khách hàng có hủy phòng hay không.
- Dự đoán tỷ lệ hủy đặt phòng trong tương lai.

Phân cụm dữ liệu (Clustering)

Là phương pháp học không giám sát dùng để chia dữ liệu thành nhiều nhóm dựa trên mức độ tương đồng.

Trong đề tài này sử dụng phân cụm để khám phá các nhóm khách hàng khác nhau.

2.3. Thuật toán phân cụm K-Means

K-Means là một trong những thuật toán phân cụm phổ biến nhất trong khai phá dữ liệu.

Thuật toán hoạt động dựa trên nguyên tắc:

- Chọn trước số cụm K.
- Khởi tạo tâm cụm.
- Tính khoảng cách từ từng điểm đến các tâm cụm.
- Gán điểm vào cụm gần nhất.
- Cập nhật tâm cụm.
- Lặp lại đến khi hội tụ.

Thuật toán giúp tìm ra các nhóm dữ liệu có đặc điểm tương đồng mà không cần dữ liệu nhãn.

Ưu điểm:

- Dễ triển khai.

- Tốc độ xử lý nhanh.
- Hoạt động tốt với dữ liệu lớn.

Nhược điểm:

- Cần xác định số cụm trước.
- Nhạy với dữ liệu ngoại lệ.
- Kết quả phụ thuộc thuộc tính đầu vào.

Trong đề tài, K-Means được sử dụng để phân chia khách hàng dựa trên:

- Thời gian đặt phòng trước.
- Giá phòng trung bình.
- Số yêu cầu đặc biệt.
- Khách hàng quay lại.

2.4. Chuẩn hóa dữ liệu bằng StandardScaler

Trong dữ liệu thực tế, các thuộc tính thường có đơn vị đo khác nhau.

Ví dụ:

- Giá phòng có thể hàng trăm đơn vị.
- Số yêu cầu đặc biệt chỉ từ 0–5.

Nếu đưa trực tiếp vào mô hình sẽ gây mất cân bằng.

Do đó cần chuẩn hóa dữ liệu bằng StandardScaler.

Công thức:

$$Z = (X - \mu) / \sigma$$

Trong đó:

- X: giá trị ban đầu
- μ : giá trị trung bình
- σ : độ lệch chuẩn

Sau chuẩn hóa:

- Trung bình ≈ 0
- Độ lệch chuẩn ≈ 1

Việc chuẩn hóa giúp K-Means hoạt động ổn định hơn.

2.5. Đánh giá mô hình bằng Silhouette Score

Silhouette Score được sử dụng để đánh giá chất lượng phân cụm.

Chỉ số này đo mức độ:

- Gắn nhau giữa các phần tử trong cùng cụm.
- Tách biệt giữa các cụm khác nhau.

Giá trị nằm trong khoảng:

- Gần 1 → phân cụm tốt.
- Gần 0 → cụm chồng lấn.
- Nhỏ hơn 0 → phân cụm kém.

Trong đề tài, nhiều giá trị K được thử nghiệm từ 2 đến 10.

Kết quả cho thấy:

- $K = 2$ cho giá trị Silhouette Score cao nhất.
- Giá trị đạt được: 0.655.

Do đó $K = 2$ được lựa chọn cho mô hình cuối cùng.

2.6. Trực quan hóa dữ liệu bằng PCA

PCA (Principal Component Analysis) là phương pháp giảm chiều dữ liệu.

Mục đích:

- Giảm số lượng thuộc tính.
- Giúp trực quan hóa dữ liệu.

Trong đề tài, dữ liệu nhiều chiều được giảm xuống còn 2 chiều để biểu diễn trên biểu đồ phân tán.

Thông qua biểu đồ PCA có thể quan sát:

- Mức độ phân tách cụm.
- Sự phân bố của dữ liệu.
- Đặc điểm từng nhóm khách hàng.

Kết quả trực quan hỗ trợ đánh giá chất lượng mô hình phân cụm.


CHƯƠNG 3. THIẾT KẾ VÀ XÂY DỰNG HỆ THỐNG

3.1. Thiết kế hệ thống

Trong đề tài này, hệ thống được xây dựng với mục tiêu thực hiện quy trình phân tích dữ liệu và phân cụm khách hàng dựa trên dữ liệu đặt phòng khách sạn. Hệ thống được phát triển bằng ngôn ngữ Python và thực hiện trên môi trường Visual Studio Code kết hợp Jupyter Notebook.

Quy trình xử lý của hệ thống được xây dựng theo các bước tuần tự nhằm đảm bảo dữ liệu được xử lý đúng trước khi đưa vào mô hình phân cụm.

Sơ đồ quy trình hệ thống



Mô tả hoạt động hệ thống

Bước đầu tiên, chương trình đọc dữ liệu đặt phòng khách sạn từ tập tin CSV. Sau khi dữ liệu được tải vào bộ nhớ, hệ thống thực hiện kiểm tra cấu trúc dữ liệu và loại bỏ các bản ghi không cần thiết.

Tiếp theo, dữ liệu được tiền xử lý nhằm giảm nhiễu và đảm bảo tính đồng nhất giữa các thuộc tính.

Sau khi hoàn thành bước xử lý dữ liệu, hệ thống lựa chọn các thuộc tính phục vụ phân cụm và thực hiện chuẩn hóa trước khi đưa vào mô hình.

Thuật toán K-Means được sử dụng để chia dữ liệu thành các nhóm khách hàng khác nhau dựa trên hành vi đặt phòng.

Cuối cùng, hệ thống đánh giá chất lượng phân cụm và trực quan hóa kết quả để hỗ trợ quá trình phân tích.

3.2. Thuật toán và quy trình xử lý dữ liệu

Đề tài sử dụng quy trình xử lý dữ liệu theo hướng khoa học dữ liệu gồm các bước sau:

Bước 1. Đọc dữ liệu

Dữ liệu được lưu dưới định dạng CSV và được đọc bằng thư viện Pandas.

Mục đích:

- Chuyển dữ liệu sang DataFrame.
- Chuẩn bị cho các bước xử lý tiếp theo.

Hàm sử dụng:

```
pd.read_csv()
```

Bước 2. Tiền xử lý dữ liệu

Sau khi đọc dữ liệu, hệ thống thực hiện:

- Kiểm tra dữ liệu thiếu.
- Xóa dữ liệu trùng lặp.
- Loại bỏ các thuộc tính không phục vụ phân cụm.

Các thuộc tính bị loại bỏ:

- Booking_ID

- booking_status

Lý do:

- Booking_ID chỉ là mã định danh.
- booking_status không phục vụ mục tiêu phân cụm.

Bước 3. Lựa chọn thuộc tính

Để giảm độ phức tạp của mô hình, đề tài chỉ lựa chọn các thuộc tính có khả năng phản ánh hành vi khách hàng.

Các thuộc tính sử dụng:

Thuộc tính	Ý nghĩa
lead_time	Số ngày đặt trước
avg_price_per_room	Giá phòng trung bình
no_of_special_requests	Số yêu cầu đặc biệt
repeated_guest	Khách hàng quay lại

Các thuộc tính trên được lựa chọn nhằm giảm số chiều dữ liệu nhưng vẫn giữ được đặc trưng hành vi.

Bước 4. Chuẩn hóa dữ liệu

Các thuộc tính có giá trị khác nhau nên cần chuẩn hóa.

Ví dụ:

- Giá phòng có giá trị lớn.
- Yêu cầu đặc biệt có giá trị nhỏ.

Nếu không chuẩn hóa sẽ làm sai lệch khoảng cách khi phân cụm.

Phương pháp sử dụng:

StandardScaler

Kết quả:

- Trung bình dữ liệu gần bằng 0.
- Độ lệch chuẩn gần bằng 1.

Bước 5. Phân cụm bằng K-Means

Sau khi chuẩn hóa, dữ liệu được đưa vào mô hình K-Means.

Quy trình:

- Chọn số cụm K.
- Khởi tạo tâm cụm.
- Gán dữ liệu vào cụm gần nhất.
- Cập nhật tâm cụm.
- Lặp đến khi hội tụ.

Đề tài thử nghiệm nhiều giá trị K từ 2 đến 10.

Kết quả đánh giá:

K	Silhouette Score
2	0.685
3	0.304
4	0.339
5	0.344
6	0.349

Kết quả cho thấy K = 2 cho chất lượng phân cụm tốt nhất.

3.3. Cấu trúc dữ liệu

Dữ liệu sử dụng trong đề tài là tập dữ liệu đặt phòng khách sạn.

Sau khi tiền xử lý, dữ liệu được giữ lại gồm các trường:

Tên cột	Kiểu dữ liệu	Chức năng
lead_time	Numeric	Thời gian đặt trước
avg_price_per_room	Numeric	Giá trung bình
no_of_special_requests	Numeric	Yêu cầu đặc biệt
repeated_guest	Numeric	Khách quay lại

Ngoài ra, hệ thống bổ sung thêm:

Tên cột	Ý nghĩa
cluster	Nhãn cụm

Cột cluster được sinh ra sau khi thực hiện phân cụm.

3.4. Xây dựng chương trình

Chương trình được xây dựng bằng Python trên môi trường Visual Studio Code.

Các thư viện sử dụng:

- Pandas
- Matplotlib
- Seaborn
- Scikit-learn

Các hàm chính:

Hàm	Chức năng
<code>read_csv()</code>	Đọc dữ liệu
<code>drop_duplicates()</code>	Xóa dữ liệu trùng
<code>StandardScaler()</code>	Chuẩn hóa
<code>KMeans()</code>	Phân cụm
<code>silhouette_score()</code>	Đánh giá
<code>PCA()</code>	Trực quan

Kết quả đầu ra của chương trình gồm:

- Dữ liệu sau xử lý.
- Kết quả phân cụm.
- Bảng thống kê đặc điểm cụm.
- Biểu đồ trực quan.

Thông qua quá trình xây dựng, hệ thống đã hoàn thành đầy đủ các bước từ xử lý dữ liệu đến phân tích kết quả và sẵn sàng cho quá trình thực nghiệm ở chương tiếp theo.

CHƯƠNG 4. THỰC NGHIỆM VÀ KẾT LUẬN

4.1. Thực nghiệm

4.1.1. Môi trường thực nghiệm

Đề tài được thực hiện bằng ngôn ngữ Python trên môi trường Visual Studio Code kết hợp Jupyter Notebook.

Cấu hình thực nghiệm:

- Hệ điều hành: Windows 11
- Ngôn ngữ lập trình: Python
- Công cụ: Visual Studio Code
- Thư viện:
 - Pandas
 - Matplotlib
 - Seaborn
 - Scikit-learn

Dữ liệu sử dụng là tập dữ liệu đặt phòng khách sạn được lưu dưới định dạng CSV.



```
df = df.drop_duplicates()

df = df.drop(
    columns=[
        "Booking_ID",
        "booking_status"
    ]
)

df.head()
```

[5] ✓ 0.0s Python

	no_of_adults	no_of_children	no_of_weekend_nights	no_of_week_nights	type_of_meal_plan	required_car_parking
0	2	0	1	2	Meal Plan 1	
1	2	0	2	3	Not Selected	
2	1	0	2	1	Meal Plan 1	
3	2	0	0	2	Meal Plan 1	
4	2	0	1	1	Not Selected	

Hình 4.1. Dữ liệu sau khi đọc vào hệ thống

4.1.2. Quy trình thực nghiệm

Quá trình thực hiện gồm các bước:

Bước 1: Đọc dữ liệu từ file CSV.

Bước 2: Làm sạch dữ liệu và loại bỏ dữ liệu không cần thiết.

Bước 3: Lựa chọn các thuộc tính phục vụ phân tích.

Bước 4: Chuẩn hóa dữ liệu bằng StandardScaler.

Bước 5: Thực hiện phân cụm bằng thuật toán K-Means.


Bước 6: Đánh giá kết quả và trực quan hóa.

4.1.3. Kết quả phân tích dữ liệu

Câu hỏi 1. Tỷ lệ khách hàng hủy đặt phòng là bao nhiêu trong toàn bộ dữ liệu?

Thực hiện thống kê trên thuộc tính trạng thái đặt phòng để xác định số lượng đặt thành công và số lượng bị hủy.

Kết quả cho thấy dữ liệu tồn tại cả hai nhóm khách hàng gồm hoàn tất đặt phòng và hủy đặt phòng. Việc xác định tỷ lệ này giúp đánh giá mức độ ổn định của hoạt động đặt phòng và làm cơ sở cho các bài toán dự đoán trong tương lai.




Hình 4.2. Biểu đồ tỷ lệ khách hàng hủy đặt phòng

Nhận xét:

Từ biểu đồ có thể thấy tỷ lệ hủy phòng chiếm khoảng 33% tổng số dữ liệu.

Câu hỏi 2. Thời gian đặt phòng trước (lead time) trung bình của khách hàng là bao nhiêu?

Thuộc tính lead_time thể hiện số ngày khách hàng đặt trước khi nhận phòng.



Hình 4.3. Biểu đồ phân bố Lead Time


Nhận xét:

Khách hàng thường có xu hướng đặt phòng trước trong khoảng thời gian nhất định thay vì đặt sát ngày.

Câu hỏi 3. Mức giá phòng trung bình có sự khác biệt như thế nào giữa các nhóm khách hàng?

Tiến hành thống kê giá phòng trung bình để đánh giá sự khác biệt giữa các nhóm khách hàng.

Kết quả:




Hình 4.4. Biểu đồ giá phòng trung bình

Nhận xét:

Có sự khác biệt về mức chi tiêu giữa các nhóm khách hàng, phản ánh đặc điểm sử dụng dịch vụ khác nhau.

Câu hỏi 4. Khách hàng thường đặt phòng vào ngày thường hay cuối tuần nhiều hơn?

Thực hiện thống kê số ngày lưu trú cuối tuần và ngày thường.




Hình 4.5. Biểu đồ số ngày lưu trú

Nhận xét:

Kết quả cho thấy khách hàng có xu hướng lưu trú nhiều hơn vào ngày thường.

Câu hỏi 5. Số lượng yêu cầu đặc biệt phân bố như thế nào trong tập dữ liệu?

Tiến hành thống kê thuộc tính số yêu cầu đặc biệt.



Hình 4.6. Phân bố số lượng yêu cầu đặc biệt

Nhận xét:

Phần lớn khách hàng chỉ đưa ra số lượng yêu cầu ở mức thấp, cho thấy nhu cầu sử dụng dịch vụ bổ sung không quá cao.


4.1.4. Kết quả phân cụm K-Means

Sau khi chuẩn hóa dữ liệu, tiến hành thử nghiệm thuật toán K-Means với nhiều giá trị K khác nhau.

Kết quả đánh giá:

K	Silhouette Score
2	0.655
3	0.196
4	0.198
5	0.202

K	Silhouette Score
6	0.217
7	0.218
8	0.226
9	0.202
10	0.203



Hình 4.7. Biểu đồ Silhouette Score theo số cụm


Nhận xét:

Kết quả cho thấy giá trị $K = 2$ đạt điểm Silhouette Score cao nhất (0.655), thể hiện khả năng phân tách cụm tốt hơn các giá trị còn lại.

Do đó mô hình cuối cùng lựa chọn:

$K = 2$

Tiếp tục thực hiện phân cụm với $K = 2$.



Hình 4.8. Kết quả trực quan hóa phân cụm bằng PCA

Nhận xét:

Kết quả trực quan cho thấy dữ liệu được chia thành hai nhóm khách hàng có sự khác biệt tương đối rõ ràng.

Tiến hành phân tích đặc điểm từng cụm.

```
cluster_summary
```

✓ 0.0s

	lead_time	avg_price_per_room	no_of_special_requests	repeated_guest
cluster				
0	87.127995	104.419030	0.621163	0.0
1	13.195699	65.589516	0.562366	1.0

Hình 4.9. Bảng đặc điểm trung bình từng cụm

Nhận xét:

Mỗi cụm thể hiện một kiểu hành vi đặt phòng khác nhau dựa trên thời gian đặt trước, giá phòng và mức độ sử dụng dịch vụ.

4.1.5. Định hướng mở rộng

Ngoài phân cụm, dữ liệu còn có thể áp dụng cho các bài toán:

Dự đoán

- Dự đoán khách hàng có hủy đặt phòng hay không.
- Dự đoán tỷ lệ hủy đặt phòng trong tương lai.

Một số mô hình có thể sử dụng:

- Logistic Regression
- Random Forest
- Decision Tree

Phân cụm mở rộng

- Phân cụm theo mức chi tiêu.
- Phân cụm theo mức độ trung thành của khách hàng.

4.2. Kết luận

Đề tài đã xây dựng thành công quy trình phân tích dữ liệu đặt phòng khách sạn bằng Python và áp dụng thuật toán K-Means để khám phá các nhóm khách hàng.

Kết quả thực nghiệm cho thấy thuật toán đạt hiệu quả tốt với giá trị $K = 2$ và Silhouette Score đạt 0.655.

Thông qua đề tài đã thực hiện được:

- Đọc và xử lý dữ liệu.
- Chuẩn hóa dữ liệu.
- Phân tích đặc điểm khách hàng.
- Phân cụm bằng K-Means.
- Đánh giá và trực quan hóa kết quả.

Qua quá trình thực hiện, đề tài giúp củng cố kiến thức về khoa học dữ liệu, kỹ thuật phân cụm và kỹ năng xử lý dữ liệu bằng Python.

Trong tương lai có thể mở rộng đề tài bằng việc thử nghiệm nhiều thuật toán khác hoặc xây dựng hệ thống phân tích trực quan hơn.

KẾT LUẬN

Sau quá trình nghiên cứu và thực hiện đề tài **“Phân tích và khám phá các nhóm khách hàng dựa trên dữ liệu đặt phòng khách sạn bằng kỹ thuật phân cụm K-Means”**, đề tài đã hoàn thành mục tiêu xây dựng quy trình phân tích dữ liệu và áp dụng kỹ thuật phân cụm để khám phá đặc điểm của khách hàng dựa trên dữ liệu đặt phòng.

Trong quá trình thực hiện, dữ liệu được xử lý qua các bước gồm đọc dữ liệu, tiền xử lý, lựa chọn thuộc tính, chuẩn hóa dữ liệu và xây dựng mô hình phân cụm bằng thuật toán K-Means. Kết quả thực nghiệm cho thấy việc sử dụng các thuộc tính như thời gian đặt phòng trước, giá phòng trung bình, số lượng yêu cầu đặc biệt và trạng thái khách hàng quay lại có thể hỗ trợ phân chia dữ liệu thành các nhóm khách hàng có đặc điểm tương đồng.

Thông qua quá trình thử nghiệm với nhiều giá trị K khác nhau, mô hình đạt kết quả tốt nhất tại $K = 2$ với Silhouette Score = 0.655, cho thấy dữ liệu có khả năng phân tách tương đối tốt giữa các nhóm. Ngoài ra, đề tài cũng thực hiện trực quan hóa dữ liệu và phân tích đặc điểm của từng cụm nhằm hỗ trợ quá trình đánh giá kết quả.

Bên cạnh việc phân cụm, đề tài còn thực hiện các bước phân tích dữ liệu mô tả nhằm tìm hiểu một số đặc điểm của tập dữ liệu như thời gian đặt phòng, mức giá trung bình, xu hướng lưu trú và phân bố các yêu cầu đặc biệt của khách hàng. Qua đó cho thấy dữ liệu có nhiều tiềm năng để tiếp tục khai thác cho các bài toán dự đoán và hỗ trợ ra quyết định.

Thông qua đề tài, sinh viên đã củng cố được kiến thức về khoa học dữ liệu, quy trình xử lý dữ liệu thực tế, kỹ thuật phân cụm và sử dụng các thư viện Python phục vụ phân tích dữ liệu.

Trong tương lai, đề tài có thể tiếp tục mở rộng bằng cách thử nghiệm thêm các thuật toán phân cụm khác, bổ sung nhiều thuộc tính hơn hoặc phát triển thành hệ thống trực quan hóa và hỗ trợ dự đoán hành vi khách hàng.

Mặc dù còn một số hạn chế về phạm vi và thời gian thực hiện, đề tài đã hoàn thành các mục tiêu đặt ra và đạt được kết quả phù hợp với yêu cầu của môn học.

TÀI LIỆU THAM KHẢO

- [1] Ahsan81, *Hotel Reservations Classification Dataset*, Kaggle. Truy cập tại: <https://www.kaggle.com/datasets/ahsan81/hotel-reservations-classification-dataset>
- [2] Aurélien Géron, *Hands-On Machine Learning with Scikit-Learn, Keras and TensorFlow*, 3rd Edition, O'Reilly Media, 2022.
- [3] Scikit-learn Development Team, *Scikit-learn Documentation – KMeans Clustering*. Truy cập tại: <https://scikit-learn.org/stable/modules/generated/sklearn.cluster.KMeans.html>
- [4] Wes McKinney, *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and Jupyter*, 3rd Edition, O'Reilly Media, 2022.